

# TP Série 1 : Analyse du Gradient et de la Convexité des Fonctions de Perte

UE : INF4127 - Optimisation II

## Membres du groupe

KUITCHE AROLLE NACHARD (22T2931)

KONZOU SODEA ALAN PEREC (22T2957)

KENFACK LEKANE FRANK (22T2841)

VOUKENG DJIOKENG CHRISTIAN ROUSSEL (22U2053)

UNIVERSITÉ DE YAOUNDÉ 1

Faculté des Sciences, Département d'Informatique

2 octobre 2025

## Objectif de l'Exercice

- **Calcul symbolique** des gradients des fonctions de perte classiques.
- Étude des **propriétés de convexité** pour chaque fonction.

### Importance

La convexité est cruciale en optimisation pour garantir que la descente de gradient converge vers un minimum global.

# Notations Utilisées

- $y$  : **Vraies étiquettes** (vecteur cible).
- $\hat{y}$  : **Prédictions** du modèle (vecteur).
- $N$  : Nombre d'échantillons.
- $e_i = y_i - \hat{y}_i$  : Erreur pour l'échantillon  $i$ .
- $\delta$  : Paramètre de la **Perte de Huber**.
- $\nabla_{\hat{y}} L$  : Gradient par rapport aux prédictions  $\hat{y}$ .

# 1. Erreur Quadratique Moyenne (MSE)

- **Formule :**

$$L_{MSE}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

→ **Gradient (Vectoriel) :**

$$\nabla_{\hat{y}} L_{MSE} = \frac{2}{N} (\hat{y} - y)$$

→ **Convexité :** La seconde dérivée est  $\frac{\partial^2 L_{MSE}}{\partial \hat{y}_i^2} = \frac{2}{N}$ .

## Conclusion

La MSE est une fonction **strictement convexe** ( $\frac{2}{N} > 0$ ).

## 2. Entropie Croisée Binaire (BCE)

- **Formule :**

$$L_{BCE}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

→ **Gradient (par composante) :**

$$\frac{\partial L_{BCE}}{\partial \hat{y}_i} = \frac{1}{N} \left( \frac{\hat{y}_i - y_i}{\hat{y}_i(1 - \hat{y}_i)} \right)$$

→ **Convexité :** La seconde dérivée est  $\frac{\partial^2 L_{BCE}}{\partial \hat{y}_i^2} = \frac{1}{N} \left[ \frac{y_i}{\hat{y}_i^2} + \frac{1-y_i}{(1-\hat{y}_i)^2} \right]$ .

### Conclusion

La BCE est **strictement convexe** (car la seconde dérivée est toujours positive pour  $\hat{y}_i \in (0, 1)$ ).

### 3. Entropie Croisée Catégorielle (CCE)

- **Formule :**

$$L_{CCE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(\hat{y}_{ik})$$

→ **Gradient (par composante  $\hat{y}_{ik}$ ) :**

$$\frac{\partial L_{CCE}}{\partial \hat{y}_{ik}} = -\frac{1}{N} \frac{y_{ik}}{\hat{y}_{ik}}$$

→ **Convexité :** La seconde dérivée est  $\frac{\partial^2 L_{CCE}}{\partial \hat{y}_{ik}^2} = \frac{1}{N} \frac{y_{ik}}{\hat{y}_{ik}^2}$ .

#### Conclusion

La CCE est **convexe** ( $\geq 0$ ).

*Note : La convexité est généralement étudiée par rapport aux logits (entrées du Softmax) pour l'optimisation.*

## 4. Perte de Huber

- Formule (pour un échantillon  $i$ , avec  $e_i = y_i - \hat{y}_i$ ) :

$$L_{\delta}(e_i) = \begin{cases} \frac{1}{2}e_i^2 & \text{si } |e_i| \leq \delta \\ \delta(|e_i| - \frac{1}{2}\delta) & \text{si } |e_i| > \delta \end{cases}$$

→ Gradient (par composante  $\hat{y}_i$ ) :

$$\frac{\partial L_{Huber}}{\partial \hat{y}_i} = -\frac{1}{N} \cdot \begin{cases} y_i - \hat{y}_i & \text{si } |e_i| \leq \delta \\ \delta \cdot \text{sgn}(y_i - \hat{y}_i) & \text{si } |e_i| > \delta \end{cases}$$

→ **Convexité** : La seconde dérivée est positive ou nulle :  $\frac{\partial^2 L_{Huber}}{\partial \hat{y}_i^2} = \frac{1}{N}$  (si  $|e_i| < \delta$ ) ou 0 (si  $|e_i| > \delta$ ).

### Conclusion

La Perte de Huber est **convexe**. Elle est moins sensible aux outliers que la MSE tout en conservant la convexité.

# Conclusion : Synthèse des Résultats

## Résumé

Toutes les fonctions de perte étudiées sont **convexes** par rapport aux prédictions  $\hat{y}$ , ce qui est fondamental pour les algorithmes d'optimisation comme la descente de gradient.

Fonction de Perte	Gradient	Propriété de Convexité
MSE	$\frac{2}{N}(\hat{y} - y)$	Strictement Convexe
BCE	$\frac{1}{N} \left( \frac{\hat{y} - y}{\hat{y} \odot (1 - \hat{y})} \right)$	Strictement Convexe
CCE	$-\frac{1}{N} \frac{y}{\hat{y}}$ (Élément par élément)	Convexe
Huber	Expression par cas	Convexe



Merci pour votre attention !